Primerjava strategij sprotnega učenja z reputacijskim mehanizmom v iterativni zapornikovi dilemi

Nik Bržan
nik.brzan@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

David Bujić
david.bujic@student.um.si
Faculty of Electrical
Engineering and Computer Science,
University of Maribor
Koroška cesta 46
SI-2000 Maribor, Slovenia

KLJUČNE BESEDE

Sprotno učenje, iterativna zapornikova dilema, reputacijski mehanizem, večagentni sistem, sodelovanje agentov

1 UVOD

Koda tega članka je prosto dostopna na naslednji povezavi: https://github.com/NBrzan/dilemmaRL. Za glavni članek je bil izbran članek o iterativni zaporniški dilemi. Poleg glavnega članka je za namene tega članka bil izbran tudi dodatni članek.

2 DEFINICIJA PROBLEMA

2.1 Osnoven opis problema

Glavni problem, ki ga ta članek obravnava predstavlja klasično družbeno dilemo: iterativna zapornikova dilema (IPD). Natančneje, članek se osredotoča na vpliv mehanizma pozornosti na vedenje agentov spletnega učenja v dilemi.

2.2 Izvor problema

Problematika članka je realne narave, saj predstavlja reševanje problemov pri nasprotujočih ciljev, kar je problem, ki ga lahko najdemo na veliko področjih. Primera teh področij so biologija, ekonomija, poleg tega pa problematiko zasledimo tudi v vsakodnevni uporabi, specifično pri peer-2-peer prenašanju datotek[2] [4].

2.3 Formulacija problema z matematično notacijo

Definicijo iterativne zapornikove dileme lahko zapišemo v matrični obliki in sicer:

$$G = [N, \{A_i\}_{i \in N}, \{R_i\}_{i \in N}] \tag{1}$$

V definiciji N predstavlja nabor agentov, medtem ko A_i predstavlja akcije, ki jih lahko i-ti agent izvede. R_i je nagradna funkcija i-tega agenta. Osnoven primer je igra z dveh agentov, kjer so možne akcije C (kooperacija) in D (prevara), rezultati pa so T (temptacija), R (nagrada), P (kazen), S (bedak). Za dane akcije in nagrade velja:

$$T > R > P > S \quad \text{in} \quad 2R > T + S \tag{2}$$

Te so v razmerju, ki je viden v tabeli 1[5].

3 PREGLED SORODNIH DEL

V tem članku avtorji uporabljajo večagentno okrepitveno učenje za odkrivanje dominantnih strategij v iterativnih igrah. Odkrili so novo strategijo »memory-two bilateral reciprocity«, ki se je izkazala boljše kot veliki del klasičnih strategij. Glavni pomen tega članka je, da globina spomina agenta neposredno vpliva na uspešnost strategije v iterativnih igrah[3].

	C	D
C	R,R	S,T
D	T,S	P,P

Tabela 1: Matrika plačil za zapornikovo dilemo dveh igralcev

V tem članku avtorji opisujejo scenarij zapornikove dileme, v katerem je omenjena reputacija kot migracijsko vedenje agentov. Avtorji so z uporabo Q-učenja in reputacijskega mehanizma dosegli večjo stopnjo kooperacije med agenti. Kombinacija med Q-učenjem in reputacijo predstavlja del osnovne ideje najinega članka[6].

V tem članku avtorji preučujejo vlogo ugleda pri kooperativnosti agentov. Agenti se s pomočjo Q-učenja naučijo ocenjevati ugled nasprotnikov na podlagi njihovih predhodnih dejanj. Informacije o nasprotnikih uporabijo za odločanje pri nadaljnjem sodelovanju. Rezultati pokažejo, da informacije o reputaciji vodijo do višje stopnje sodelovanja v primerjavi z agenti, ki nimajo dostopa do teh informacij. Ta članek neposredno podpira našo idejo za izboljšavo [1].

4 OPIS OVREDNOTENJA PRISTOPA OZ. METRIK

Stopnja kooperativnosti (CR) meri delež kooperativnih akcij agenta g_k čez vse krogle celotnega turnirja:

$$CR_k = \frac{\sum_{t=1}^{N \cdot (K-1)} \mathbf{1}[a_k^t = C]}{N \cdot (K-1)}, \tag{3}$$

kjer $\mathbf{1}[\cdot]$ označuje indikatorsko funkcijo, ki vrne vrednost 1, če je pogoj izpolnjen, in 0 sicer. Višja vrednost CR pomeni, da se agent pogosteje odloča za sodelovanje. Ta metrika se uporablja kot kazalec kooperativnosti agentov in pri primerjavi dominantnih strategij[3][6].

Hitrost konvergence (T_{conv}) meri število krogov, ki jih agent potrebuje, da njegova vrednost kooperativnosti doseže stabilno vrednost oz. konvergira. Konvergenco lahko izračunamo po enačbi:

$$T_{conv} = \min\{t : \text{std}(CR_{t-w}, \ldots, CR_t) < \epsilon\} \tag{4}$$

Agenti z dostopom do reputacijskih informacij hitreje konvergirajo k stabilnemu kooperativnemu vedenju, saj imajo na voljo bogatejši kontekst za odločanje že od prvih interakcij[1].

5 NAČRT REŠITVE

5.1 Opis predvidene nadgradnje

Naša rešitev uvaja modul za reputacijo, ki agentom omogoča dostop do agregirane informacije o preteklem vedenju nasprotnika, še preden se z njim neposredno srečajo v turnirju. To rešitev bomo primerjali z rešitvijo glavnega članka.

5.2 Načrt dela

Načrt dela je porazdeljen med več sprintov, ki se bodo sproti prilagajali.

- Sprint 1:
  - Ustvarjanje repozitorija git za nalaganje in dostop do programske kode
  - Poglavje Uvod (razlaga večagentnih sistemov, teorije iger, iterativne zapornikove dileme)
  - Poglavje Sorodna dela (razlaga metod in rezultatov izbranih člankov)
  - Priprava eksperimentalnega okolja
  - Pregled in prilagoditev naše nadgraditve (dodatek reputacije)
- Sprint 2:
  - Dokončanje poglavja Uvod
  - Dokončanje poglavja Sorodna dela
  - Poglavje Metodologija (opis priprave okolja za iterativno zapornikovo dilemo, pravil turnirja, uporabljenih strategij oz. modelov in reputacijskega mehanizma)
  - Poglavje Eksperiment in analiza rezultatov
  - Reprodukcija rezultatov člankov navedenih v Uvodu Načrta razvoja potrebni za kasnejšo analizo
  - Implementacija ideje
  - Implementacija eksperimenta
  - Končen plan nadgraditve eksperimenta (dodatek reputacije)
- Sprint 3:
  - Dokončanje poglavja Metodologija
  - Poglavje Eksperiment in analiza rezultatov
  - Implementacija naše ideje (dodatek reputacije)
  - Implementacija metrik
  - Zagon lastnega eksperimenta
- Sprint 4:
  - Dokončanje poglavja Eksperimenti in analiza rezultatov
  - Poglavje Zaključek
  - Poglavje Povzetek
  - Analiza rezultatov na podlagi predlaganih metrik

Poleg opisa, je načrt poteka, prikazan tudi z Ganttovim diagramom 1. Struktura projekta, pa je opisana z UML diagramom 2.

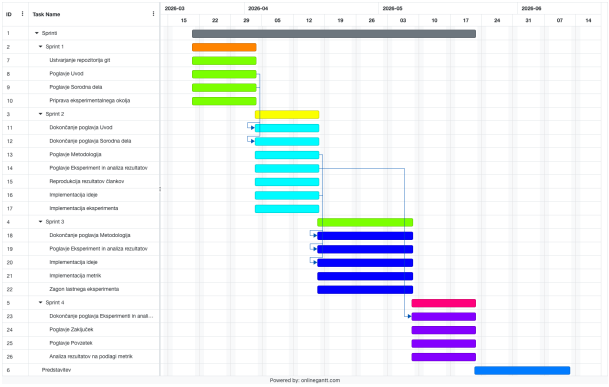

Slika 1: Ganttov diagram sprintov

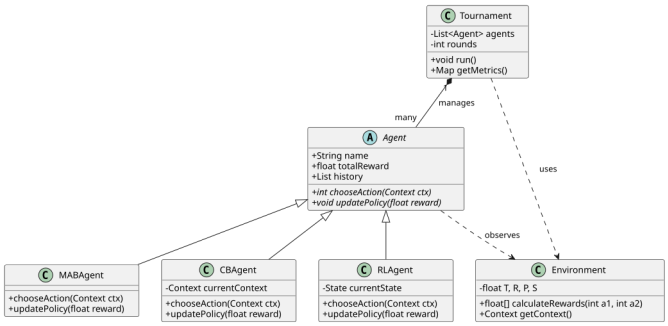

Slika 2: UML diagram razredov za arhitekturo agentov in okolja v IPD

LITERATURA

[1] Nicolas Anastassacos, Julian García, Stephen Hailes, and Mirco Musolesi. 2021. Cooperation and reputation dynamics with reinforcement learning. *arXiv preprint arXiv:2102.07523* (2021).

[2] Bram Cohen et al. 2003. Incentives build robustness in BitTorrent. In *Workshop on Economics of Peer-to-Peer systems*, Vol. 6. 68–72.

[3] Zhenghui Fang, Haojie Xu, Chen Xie, Xiuyu Yue, Tina P. Benko, and Changwei Huang. 2025. Evolution of cooperation in multi-agent systems driven by reputation-based migration. *Chaos, Solitons Fractals* 200 (2025), 117115. https://doi.org/10.1016/j.chaos.2025.117115

[4] Marko Jurišić, Dragutin Kermek, and Mladen Konecki. 2012. A review of iterated prisoner's dilemma strategies. In *2012 Proceedings of the 35th International Convention MIPRO*. 1093–1097.

[5] Baihan Lin, Djallel Bouneffouf, and Guillermo Cecchi. 2022. Online Learning in Iterated Prisoner's Dilemma to Mimic Human Behavior. In *PRICAI 2022: Trends in Artificial Intelligence*, Sankalp Khanna, Jian Cao, Quan Bai, and Guandong Xu (Eds.). Springer Nature Switzerland, Cham, 134–147.

[6] Qi Su, Hongyu Wang, Yu Xia, and Long Wang. 2025. A multi-agent reinforcement learning framework for exploring dominant strategies in iterated and evolutionary games. *Nature Communications* (2025). https://doi.org/10.1038/s41467-025-67178-6